

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ИМЕНИ
Н.Э. БАУМАНА (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)»
Факультет Информатика и системы управления
Кафедра Программное обеспечение ЭВМ и информационные технологии

ИНФОРМАЦИОННО-ПОИСКОВЫЕ СИСТЕМЫ

ОТЧЁТ

по лабораторной работе №1

Предобработка текстовых данных
для анализа судебных документов

Поле	Значение
Студент	<u>Сапожков А.М.</u>
Группа	<u>ИУ7-43М</u>
Специальность	<u>Программная инженерия</u>
Преподаватель	<u>Курашкин С.О.</u>
Дата сдачи	<u></u>
Оценка	<u></u>

Contents

1	Цель и задачи работы	2
2	Краткая теоретическая справка	3
2.1	Предобработка текстовых данных	3
2.2	Ключевые операции NLP-конвейера	3
3	Ход выполнения работы	4
3.1	Анализ корпуса (Задание 1.1)	4
3.2	Очистка текста (Задания 2.1–2.2)	4
3.3	Токенизация и удаление стоп-слов (Задания 3.1–3.2)	5
3.4	Лемматизация (Задания 4.1–4.2)	6
3.5	Извлечение именованных сущностей (Задания 5.1–5.2)	7
3.6	Ключевое-словарная классификация (Задания 6.1–6.2)	9
3.7	Визуализация результатов (Задания 7.1–7.3)	10
4	Ответы на контрольные вопросы	13
4.1	Вопрос 1. Лемматизация и стемминг: сравнение	13
4.2	Вопрос 2. Стоп-слова и качество классификации	13
4.3	Вопрос 3. Ограничения ключевое-словарного классификатора	14
4.4	Вопрос 4. Специализированные библиотеки для русскоязычных текстов .	15
5	Индивидуальное задание	17
5.1	Добавленные документы	17
5.2	Обновлённые результаты классификации	17
5.3	Аналитический вывод	17
6	Заключение	20
	Список литературы	21
	Приложение. Сводная ведомость баллов	23

1. Цель и задачи работы

Целью настоящей лабораторной работы является освоение методов предобработки текстовых данных применительно к корпусу судебных документов, а также формирование практических навыков применения инструментов обработки естественного языка (NLP) на языке программирования Python.

В ходе выполнения работы студент решает следующие задачи:

1. Формирование и первичный анализ учебного корпуса судебных актов.
2. Реализация конвейера очистки текстовых данных.
3. Токенизация, нормализация регистра и фильтрация стоп-слов.
4. Морфологическая нормализация (лемматизация) с применением библиотеки `ru morphology2`.
5. Извлечение именованных сущностей (NER) с применением библиотеки `natasha`.
6. Реализация ключевое-словарного классификатора документов.
7. Количественный анализ корпуса и визуализация результатов.

2. Краткая теоретическая справка

Подробное изложение теоретического материала представлено в конспектах Лекции 1 («Введение в информационно-аналитические системы в юридической практике») и Лекции 2 («Сбор и предобработка данных для анализа судебной практики»).

2.1. Предобработка текстовых данных

Предобработка данных представляет собой совокупность методов, приводящих исходный неструктурированный текст в форму, пригодную для применения алгоритмов машинного обучения. Качество предобработки напрямую определяет качество последующей аналитики: неудалённые артефакты форматирования, нелемматизированные словоформы или сохранённые стоп-слова снижают точность моделей классификации [2].

2.2. Ключевые операции NLP-конвейера

Токенизация — процесс разбиения текста на минимальные смысловые единицы (токены). Является обязательным первым шагом любого NLP-конвейера.

Лемматизация — приведение слова к его нормальной словарной форме с учётом морфологических свойств. Для русскоязычных текстов применяется библиотека `rumorphy2`, обеспечивающая морфологический анализ на основе словарей `OpenCorpora`.

Стоп-слова — частотные служебные слова (предлоги, союзы, местоимения), не несущие самостоятельного смысла и удаляемые при анализе текста.

Распознавание именованных сущностей (NER, Named Entity Recognition) — задача выделения из текста упоминаний объектов реального мира (персон, организаций, дат) и их классификации по типам [1]. В данной работе используется библиотека `natasha`, специализированная для обработки русскоязычных текстов.

3. Ход выполнения работы

3.1. Анализ корпуса (Задание 1.1)

В ходе первичного анализа учебного корпуса были получены результаты по количеству документов и среднему объёму текста по категориям.

Table 3.1. Результаты анализа корпуса судебных документов

Категория	Количество документов	Средний объём (символы)
Оспаривание сделок должника	3	568.3
Субсидиарная ответственность	3	494.0
Обжалование налоговых решений	2	564.5
Включение в реестр требований кредиторов	2	494.0
Итого	10	530.2 (среднее)

3.2. Очистка текста (Задания 2.1–2.2)

Были реализованы функции очистки текста. Ниже приведён исходный код и пояснения к каждому шагу.

```
1 def normalize_whitespace(text: str) -> str:
2     """Нормализует пробельные символы."""
3     # Заменяем все последовательности пробельных символов (\s+)
4     # на единственный пробел, удаляем пробелы в начале и конце
5     text = re.sub(r'\s+', ' ', text).strip()
6     return text
7
8
9 def remove_punctuation(text: str) -> str:
10    """Удаляет знаки пунктуации, сохраняя дефисы внутри слов."""
11    # Сначала заменяем дефисы-разделители (не находящиеся между бу
        квами)
12    # на пробел, затем удаляем оставшуюся пунктуацию
```

```

13     text = re.sub(r'(?<![a-яА-Яа-зА-З])-(?![a-яА-Яа-зА-З])', ' ',
14                  text)
15     text = text.translate(str.maketrans('', '',
16                  string.punctuation))
17     return text
18
19 def clean_text(text: str) -> str:
20     """Полный конвейер очистки текста."""
21     text = remove_html_tags(text)
22     text = remove_special_chars(text)
23     text = normalize_whitespace(text)
24     return text.lower()

```

Listing 3.1. Реализация функций очистки текста

Table 3.2. Пример результата очистки текста

Этап	Текст (фрагмент)
Исходный текст	Арбитражный суд г. Москвы рассмотрел заявление конкурсного управляющего ООО 'Строй-Инвест' Иванова А.П. о признании недействительной сделки — договора купли-продажи...
После очистки	арбитражный суд г. москвы рассмотрел заявление конкурсного управляющего ооо 'строй-инвест' иванова а.п. о признании недействительной сделки договора купли-продажи...

3.3. Токенизация и удаление стоп-слов (Задания 3.1–3.2)

Было проведено обоснование выбора дополнительных юридических стоп-слов. Ниже приведены результаты токенизации.

В дополнение к базовому набору стоп-слов NLTK были добавлены следующие юридические термины:

Процессуальные термины: суд, суда, судебный, арбитражный, решение, решения, дело, дела, заявление, заявления, рассмотрение, рассмотрев, установил, установлено, признал, признать, удовлетворить, удовлетворено, отказать, отказано.

Ролевые обозначения: истец, истца, ответчик, ответчика, заявитель, заявителя, кредитор, кредитора, должник, должника, управляющий, управляющего.

Документы и акты: договор, договора, контракт, контракта, акт, акта, протокол, протокола.

Временные и указательные слова: дата, даты, момент, момента, период, периода, год, года, году, лет, число, числа, настоящий, данного, данный, который, которого, такой, такого.

Прочие часто встречающиеся слова: право, права, закону, закон, статья, статьи, статье, ст, пункт, пункта, пункту, п, часть, части, частью, основание, основания, основанию, порядок, порядка, порядку.

Обоснование: Данные слова встречаются в большинстве судебных актов независимо от их категории и не несут дифференцирующей информации для задач классификации. Их удаление позволяет алгоритму фокусироваться на содержательных терминах, специфичных для каждой категории дел.

Table 3.3. Пример токенизации документа А40-001-2023

Параметр	Значение
Документ	А40-001-2023
Категория	Оспаривание сделок должника
Первые 15 токенов	['москвы', 'конкурсного', 'ооо', 'иванова', 'признании', 'недействительной', 'сделки', 'нежилых', 'помещений', 'заключённого', 'ооо', 'соответствии', 'федерального', 'несостоятельности', 'банкротстве']

3.4. Лемматизация (Задания 4.1–4.2)

Была реализована функция `lemmatize_tokens`. Продемонстрировано, что лемматизация объединяет словоформы одного слова.

```

1 morph = pymorphy2.MorphAnalyzer()
2
3 def lemmatize_tokens(tokens: list) -> list:
4     """
5     Приводит список токенов к нормальной форме с помощью
        pymorphy2.
```

```

6     Возвращает список лемм.
7     """
8     lemmas = []
9     for token in tokens:
10         lemma = morph.parse(token)[0].normal_form
11         lemmas.append(lemma)
12     return lemmas

```

Listing 3.2. Реализация функции лемматизации

Для наглядности проведено сравнение частотных словарей до и после лемматизации. Пример оформления представлен в таблице 3.4. Таблица заполнена данными из первого документа корпуса.

Table 3.4. Сравнение частотных словарей до и после лемматизации (топ-10)

#	Токен	Частота	Лемма	Частота
1	москвы	1	москва	1
2	конкурсного	1	конкурсый	1
3	ooo	2	ooo	2
4	иванова	1	иванов	1
5	признании	1	признание	1
6	недействительной	1	недействительный	1
7	сделки	1	сделка	1
8	нежилых	1	нежилой	1
9	помещений	1	помещение	1
10	заклѹчѹнного	1	заклѹчить	1

3.5. Извлечение именованных сущностей (Задания 5.1–5.2)

Были получены результаты работы NER-модуля. Ниже приведены наблюдения относительно точности.

Распознаваемые типы сущностей:

- ORG — Организации (ООО, ПАО, ЗАО, Арбитражный суд)
- PER — Персоны (люди с фамилией и инициалами)

Table 3.5. Именованные сущности в документе A40-001-2023

Тип	Сущность
ORG	Арбитражный суд
LOC	Москвы
ORG	ООО 'Строй-Инвест'
PER	Иванова А.П.
ORG	ООО 'Партнёр'

Table 3.6. Сводная таблица именованных сущностей по корпусу

Организации (ORG)		Персоны (PER)	
Название	Частота	ФИО	Частота
Арбитражный суд	5	Иванова А.П.	1
ООО 'Партнёр'	2	Петрова Д.С.	1
ООО 'Строй-Инвест'	1	Сидоровым В.И.	1
Арбитражного суда	1	Сидоровой О.Н.	1
ЗАО 'Балтик Трейд'	1	Кузнецова М.В.	1

- LOC — Локации (города, области)

Хорошо распознаются:

- Организации с чёткой формой: ООО, ПАО, ЗАО + название в кавычках
- Судебные органы: «Арбитражный суд» определяется как ORG
- Персоны с фамилией и инициалами (Фамилия И.О.)
- Географические названия (города, области)

Возможные ошибки/ограничения:

- Дублирование сущностей — одна и та же организация может быть извлечена несколько раз
- Частичное извлечение названий — «Арбитражный суд» без указания города/региона
- Физические лица без инициалов могут не определяться как PER
- Государственные органы (ИФНС, налоговая служба) могут определяться не всегда корректно

3.6. Ключевое-словарная классификация (Задания 6.1–6.2)

Описан принцип работы реализованного классификатора. Указаны леммы, добавленные в словарь, и основания для их добавления.

```

1 KEYWORD_DICT = {
2     "Оспаривание сделок должника": [
3         "сделка", "недействительный", "оспаривание",
4         "подозрительный", "предпочтение", "зачёт",
5         "договор", "купля", "продажа", "дарение",
6         "ущерб", "кредитор", "имущество", "возврат",
7         "стоимость", "цена", "неплатёжеспособность"
8     ],
9     "Субсидиарная ответственность": [
10        "субсидиарный", "ответственность", "контролировать",
11        "генеральный", "директор", "довести",
12        "банкротство", "актив", "вывод", "аффилированный",
13        "структура", "взыскать", "задолженность", "солидарный",
14        "участник", "директор", "управляющий", "документация"
15    ],
16    "Обжалование налоговых решений": [
17        "налог", "доначисление", "вычет",
18        "ифнс", "налогоплательщик", "трансфертный",
19        "прибыль", "ндс", "добавленный", "стоимость",
20        "контрагент", "технический", "компания", "хозяйственный",
21        "операция", "доказательство", "налоговый"
22    ],
23    "Включение в реестр требований кредиторов": [
24        "реестр", "требование", "кредитор",
25        "очередь", "включение", "банк",
26        "задолженность", "кредит", "договор", "залог",
27        "обеспеченный", "третий", "отказать", "удовлетворить",
28        "заявление", "основание", "корпоративный", "заём"
29    ]
30 }
```

Listing 3.3. Расширенный словарь ключевых лемм

Результаты классификации представлены в таблице 3.7.

Table 3.7. Результаты ключевое-словарной классификации документов

ID документа	Истинная категория		Предсказанная категория		Верно
A40-001-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A40-002-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A56-003-2023	Субсидиарная	ответственность	Субсидиарная	ответственность	Да
A56-004-2023	Субсидиарная	ответственность	Субсидиарная	ответственность	Да
A60-005-2023	Обжалование	налоговых решений	Обжалование	налоговых решений	Да
A60-006-2023	Обжалование	налоговых решений	Обжалование	налоговых решений	Да
A07-007-2023	Включение в реестр	требований кредиторов	Включение в реестр	требований кредиторов	Да
A07-008-2023	Включение в реестр	требований кредиторов	Включение в реестр	требований кредиторов	Да
A40-009-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A40-010-2023	Субсидиарная	ответственность	Субсидиарная	ответственность	Да
Точность					10/10 = 100.0%

3.7. Визуализация результатов (Задания 7.1–7.3)

Были построены графики и облака слов. Каждый рисунок сопровождается подписью и пояснительным текстом.

На рисунке 3.1 показана диаграмма распределения документов по категориям. Корпус сбалансирован: категории «Оспаривание сделок должника» и «Субсидиарная ответственность» представлены по 3 документа, категории «Обжалование налоговых решений» и «Включение в реестр требований кредиторов» — по 2 документа.

На рисунке 3.2 представлено облако слов по всему корпусу. Наиболее крупно отображены термины, часто встречающиеся в судебных документах: «банкротство», «должник», «кредитор», «сделка», «ответственность», «налог», «требование», «реестр»,




Figure 3.1. Диаграмма распределения документов по категориям

«договор».

На рисунках 3.3–3.4 показаны отдельные облака слов для каждой категории. Анализ показывает, что лексика разных категорий имеет как уникальные термины (например, «субсидиарный» для субсидиарной ответственности, «ндс» для налоговых споров), так и общие слова (например, «должник», «кредитор», «договор»). Наличие общих терминов может приводить к ошибкам классификации на смешанных документах при использовании словарного подхода.




Figure 3.2. Облако слов по всему корпусу (лемматизированные токены)




Figure 3.3. Облака слов по категориям: «Оспаривание сделок должника» (слева) и «Субсидиарная ответственность» (справа)




Figure 3.4. Облака слов по категориям: «Обжалование налоговых решений» (слева) и «Включение в реестр требований кредиторов» (справа)

4. Ответы на контрольные вопросы

4.1. Вопрос 1. Лемматизация и стемминг: сравнение

Чем лемматизация отличается от стемминга? В каких сценариях предпочтительнее использование каждого из методов применительно к юридическим текстам?

Лемматизация приводит слово к его нормальной словарной форме (лемме) с учётом морфологических свойств и части речи. Например: «рассматривающий» → «рассматривать», «судами» → «суд».

Стемминг отсекает окончания и суффиксы, оставляя только основу слова (стем), часто не являющуюся реальным словом. Например: «рассматривающий» → «рассматрив», «судами» → «суд».

Отличия:

- Лемматизация даёт реальное слово, стемминг — основу (может не быть словом)
- Лемматизация медленнее, но точнее; стемминг быстрее, но менее точен
- Лемматизация учитывает часть речи, стемминг — нет

Для юридических текстов предпочтительна лемматизация, потому что:

1. Юридическая терминология требует точности (например, «ответственность» != «ответ»)
2. Поиск по судебной практике должен находить точные термины, а не основы
3. Русская морфология сложна — стемминг даёт много ошибок (например, «истец» → «ист», «должник» → «должн»)

Стемминг может быть полезен для быстрой предобработки больших объёмов данных, когда скорость важнее точности.

4.2. Вопрос 2. Стоп-слова и качество классификации

Почему удаление стоп-слов улучшает качество классификации текстов? Можно ли привести пример, когда удаление стоп-слов было бы вредным?

Удаление стоп-слов улучшает классификацию, потому что:

1. Снижает размерность признакового пространства — меньше шума, быстрее обучение

2. Убирает слова, не несущие смысловой нагрузки — предлоги, союзы, местоимения одинаковы во всех документах
3. Повышает вес содержательных терминов — ключевые слова становятся более значимыми
4. Уменьшает переобучение — модель не запоминает случайные сочетания служебных слов

Пример, когда удаление стоп-слов вредно:

- Поиск цитат и устойчивых выражений — фраза «быть или не быть» потеряет смысл без «или» и «не»
- Анализ тональности — отрицание «не» критически важно: «не удовлетворить» != «удовлетворить»
- Юридические формулировки — некоторые служебные слова меняют смысл:
 - «вправе отказать» != «отказать»
 - «не подлежит удовлетворению» != «подлежит удовлетворению»
- Поиск точных совпадений — при поиске прецедентов важно сохранять исходную формулировку

Вывод: Для классификации судебных документов по категориям удаление стоп-слов полезно, но при анализе правовых нюансов и отрицаний требуется осторожность.

4.3. Вопрос 3. Ограничения ключевое-словарного классификатора

Каковы принципиальные ограничения ключевое-словарного классификатора, реализованного в Части 6? Какими методами можно преодолеть эти ограничения?

Ограничения ключевое-словарного классификатора:

Ограничение	Описание
Жёсткие правила	Требует ручного составления и обновления словаря
Нет контекста	Не учитывает окружение слова, только наличие
Синонимы	Не распознаёт синонимы, не входящие в словарь
Многозначность	Не различает значения слова в разных контекстах
Новые термины	Не работает с терминами, отсутствующими в словаре
Смешанные документы	Ошибается на документах с несколькими темами

Методы преодоления (из Лекции 2):

1. Машинное обучение с учителем — обучение модели на размеченных данных (логистическая регрессия, SVM, нейронные сети)
2. TF-IDF векторизация — учёт важности слов относительно документа и корпуса
3. N-граммы — анализ сочетаний слов, а не отдельных токенов
4. Word embeddings — векторные представления слов (Word2Vec, GloVe, FastText)
5. Анализ статей закона — классификация по упоминаниям конкретных правовых норм
6. NER + классификация — использование именованных сущностей как признаков
7. Ансамбли моделей — комбинация нескольких подходов для улучшения точности

4.4. Вопрос 4. Специализированные библиотеки для русскоязычных текстов

Почему для русскоязычных юридических текстов предпочтительно использование специализированных библиотек, таких как *natasha*, вместо универсальных решений?

Преимущества *natasha* для русских юридических текстов:

Критерий	<i>natasha</i>	<i>spaCy</i> (ru)
Обучение	На русских новостях и документах	На общих текстах
NER-модели	Специализированы для русского языка	Мультязычная модель
Распознавание имён	Высокая точность для русских ФИО	Ниже для сложных форм
Организации	Хорошо распознаёт ООО, ПАО, ЗАО	Может пропускать формы
Поддержка	Активная разработка для RU	Ограниченная для ru

Причины предпочтения *natasha*:

1. Доменная специфика — обучена на русских текстах, близких к юридическому стилю
2. Формы организаций — точно распознаёт российские правовые формы (ООО, ПАО, ИП, АО)
3. Русские имена — лучше обрабатывает ФИО с инициалами, фамилии в разных падежах

4. Морфология — учитывает сложную русскую морфологию и падежные окончания
5. Интеграция — работает в связке с `ru morphology2` для полной обработки текста

Когда `sraCy` может быть полезен:

- Мультиязычные проекты
- Нужна высокая скорость обработки
- Требуется интеграция с другими компонентами `sraCy`

5. Индивидуальное задание

5.1. Добавленные документы

В данном разделе представлены результаты самостоятельного расширения корпуса. Было добавлено пять новых документов.

Table 5.1. Таблица добавленных документов

ID	Категория	Источник	Объём (символы)
A40-011-2023	Оспаривание сделок должника	kad.arbitr.ru	448
A56-012-2023	Субсидиарная ответственность	kad.arbitr.ru	427
A60-013-2023	Обжалование налоговых решений	kad.arbitr.ru	414
A07-014-2023	Включение в реестр требований кредиторов	kad.arbitr.ru	390
A40-015-2023	Оспаривание сделок должника	kad.arbitr.ru	402

5.2. Обновлённые результаты классификации

Были получены обновлённые результаты классификации для расширенного корпуса.

Обновлённая точность классификатора: $15 / 15 = 100.0\%$.

5.3. Аналитический вывод

После добавления 5 новых документов в корпус и повторного запуска конвейера предобработки результаты классификации остались стабильно высокими — 100% точность как на исходном корпусе (10/10), так и на расширенном (15/15).

Ключевые наблюдения:

1. Стабильность классификатора. Высокая точность сохранилась благодаря тому, что новые документы содержат чётко выраженные ключевые термины своих категорий. Например, документ A40-011-2023 содержит леммы «сделка», «недействительный договор», «имущество», которые однозначно указывают на категорию «Оспаривание сделок должника».
2. Сбалансированность корпуса. Расширение корпуса не нарушило баланс категорий

— все классы представлены равномерно (3-5 документов), что предотвращает смещение классификатора в сторону доминирующих категорий.

3. Качество словаря. Существующий словарь ключевых слов оказался достаточным для корректной классификации новых документов без дополнительной настройки. Это свидетельствует о хорошем охвате терминологии предметной области.

Потенциальные риски при дальнейшем масштабировании:

- При добавлении документов со смешанной тематикой (например, дела, где оспаривание сделок сочетается с субсидиарной ответственностью) точность может снизиться
- Новые термины и формулировки, не представленные в словаре, потребуют его расширения
- При увеличении корпуса до сотен документов ручное поддержание словаря станет непрактичным

Рекомендации по улучшению:

1. Автоматизировать пополнение словаря через анализ TF-IDF весов терминов
2. Внедрить машинное обучение (логистическая регрессия, SVM) для обработки смешанных документов
3. Использовать анализ статей закона как дополнительный признак классификации

Table 5.2. Результаты классификации расширенного корпуса

ID документа	Истинная категория		Предсказанная категория		Верно
A40-001-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A40-002-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A56-003-2023	Субсидиарная ответственность		Субсидиарная ответственность		Да
A56-004-2023	Субсидиарная ответственность		Субсидиарная ответственность		Да
A60-005-2023	Обжалование налоговых решений		Обжалование налоговых решений		Да
A60-006-2023	Обжалование налоговых решений		Обжалование налоговых решений		Да
A07-007-2023	Включение в реестр требований кредиторов		Включение в реестр требований кредиторов		Да
A07-008-2023	Включение в реестр требований кредиторов		Включение в реестр требований кредиторов		Да
A40-009-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A40-010-2023	Субсидиарная ответственность		Субсидиарная ответственность		Да
A40-011-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
A56-012-2023	Субсидиарная ответственность		Субсидиарная ответственность		Да
A60-013-2023	Обжалование налоговых решений		Обжалование налоговых решений		Да
A07-014-2023	Включение в реестр требований кредиторов		Включение в реестр требований кредиторов		Да
A40-015-2023	Оспаривание	сделок должника	Оспаривание	сделок должника	Да
Точность					15/15 = 100.0%

6. Заключение

По итогам выполнения лабораторной работы были решены все поставленные задачи. Реализован полный конвейер предобработки текстовых данных применительно к корпусу судебных актов, включающий очистку текста, токенизацию, фильтрацию стоп-слов, лемматизацию и извлечение именованных сущностей. На основе разработанного конвейера построен ключевое-словарный классификатор и проведена его апробация на учебном корпусе.

В ходе выполнения лабораторной работы были освоены методы предобработки текстовых данных и получены практические навыки работы с библиотеками Python для NLP. Наиболее полезными оказались:

- `py morphology2` — для лемматизации русскоязычных текстов
- `natasha` — для распознавания именованных сущностей в юридических документах
- `nltk` — для токенизации и работы со стоп-словами

Основную сложность вызвала настройка функций очистки текста, особенно сохранение дефисов внутри слов при удалении пунктуации. Однако после отладки конвейер начал работать корректно.

Ключевое-словарный классификатор показал 100% точность на учебном корпусе (10/10), а также на расширенном корпусе после добавления 5 новых документов (15/15). Высокая точность объясняется чёткой терминологической спецификой каждой категории. В ходе индивидуального задания было выявлено, что существующий словарь ключевых слов достаточен для классификации новых документов без дополнительной настройки.

Для улучшения результатов в реальных условиях целесообразно применение методов машинного обучения (TF-IDF + логистическая регрессия) и расширение словаря ключевых слов на основе анализа большего корпуса документов.

Список литературы

Bibliography

- [1] Материалы Лекции 1 по дисциплине «Информационно-поисковые системы». РУДН, 2025.
- [2] Материалы Лекции 2 по дисциплине «Информационно-поисковые системы». РУДН, 2025.
- [3] Документация библиотеки pymorphy2. URL: <https://pymorphy2.readthedocs.io>
- [4] Документация библиотеки natasha. URL: <https://natasha.github.io>
- [5] Документация библиотеки NLTK (Natural Language Toolkit). URL: <https://www.nltk.org>
- [6] Электронная картотека арбитражных дел. URL: <https://kad.arbitr.ru>

Приложение. Сводная ведомость баллов

Критерий оценивания	Максимум	Получено
Часть 2. Очистка текста (Задания 2.1–2.2)	20	
Часть 3. Токенизация и стоп-слова (Задания 3.1–3.2)	15	
Часть 4. Лемматизация (Задания 4.1–4.2)	15	
Часть 5. Извлечение сущностей (Задания 5.1–5.2)	20	
Часть 6. Классификация (Задания 6.1–6.2)	15	
Задание 7.3 (повышенная сложность)	15	
Индивидуальное задание	15	
ИТОГО	100	

Подпись преподавателя: _____

Дата проверки: _____