



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

Лабораторная работа № 3 по дисциплине «Проектирование рекомендательных систем»

Тема Фильтрация на основе контента

Студент Сапожков А.М.

Группа ИУ7-33М

Преподаватель Быстрицкая А.Ю.

Москва, 2025

1 Краткое описание Латентного преобразования Дирихле

LDA (Latent Dirichlet Allocation) — это генеративная вероятностная модель, представляющая документы как смеси латентных тем. Каждая тема характеризуется распределением вероятностей над словами словаря. Модель предполагает, что документы порождаются процессом Дирихле, где сначала выбирается распределение тем документа, затем для каждого слова выбирается тема и слово из соответствующего тематического распределения. Обучение модели осуществляется методами приближенного байесовского вывода, такими как вариационный ЕМ-алгоритм или сэмплирование по Гиббсу. Результатом являются два распределения: слов по темам и тем по документам.

2 Особенности реализации алгоритма

В качестве языка программирования для реализации алгоритмов был выбран язык программирования Python, разработка велась в среде Jupyter Notebook, позволяющей выполнять программу поэтапно, выводя на экран промежуточные результаты вычислений.

Для тестирования разработанного алгоритма использовалась облачная платформа Google Colab, не требующая установки ПО на локальный компьютер.

Для анализа был взят роман-эпопея Л.Н. Толстого «Война и мир». Этапы предобработки текста:

- 1) разбиение на главы внутри томов и частей;
- 2) приведение к нижнему регистру;
- 3) фильтрация цифр и символов, не являющихся символами русского, французского или немецкого алфавита;
- 4) токенизация;
- 5) фильтрация стоп-слов;
- 6) лемматизация (нормализация слов).

Обработка текста была выполнена с помощью модели LDA, для которой задавалось предположительное количество тем в тексте. Значения остальных параметров подбирались автоматически.

3 Результаты исследования

После предобработки исходного текста из него был сформирован словарь, из которого были отфильтрованы слишком часто или слишком редко встречающиеся слова. Минимальный порог частоты — 15, максимальный — 1000. На рисунках 3.1 и 3.2 представлены гистограммы распределения частот слов в тесте до и после фильтрации. Суммарное число элементов в словаре сократилось с 20333 слов до 2346.

Для подбора оптимального количества тем в тексте использовался показатель когерентности тем. Когерентность LDA — это метрика оценки семантической согласованности тем, измеряющая степень статистической связи между наиболее вероятными словами внутри темы. Высокая когерентность указывает на тесную семантическую связь между топовыми словами темы, что свидетельствует о её содержательной целостности и интерпретируемости. На рисунке 3.3 представлена зависимость когерентности тем от заданного количества тем в тексте. Для дальнейших исследований было взято оптимальное значение — 18 тем.

На рисунке 3.4 представлена визуализация тем в пространстве слов, полученная с помощью алгоритма PCA. Применение данного алгоритма помогло значительно отделить от остальных только темы 4, 5, 10, 15 и 18.

На рисунке 3.5 представлена визуализация самых популярных слов в темах, полученная с помощью алгоритма UMAP. Применение данного алгоритма помогло значительно отделить от остальных все темы текста, кроме 1.

На рисунках 3.6 и 3.7 представлен анализ сходства тем в тексте. Среди тем наименее похожей на остальные является тема 10, так как в ней преобладают слова на французском языке.




Рисунок 3.1 — Распределение частот слов в тексте до фильтрации




Рисунок 3.2 — Распределение частот слов в тексте после фильтрации



Рисунок 3.3 — Зависимость когерентности тем от заданного количества тем в тексте




Рисунок 3.4 — Темы в пространстве слов (PCA)




Рисунок 3.5 — Самые популярные слова в каждой теме текста (UMAP)




Рисунок 3.6 — Матрица сходства между темами текста



Рисунок 3.7 — Распространённость тем в главах текста

ЗАКЛЮЧЕНИЕ

В рамках лабораторной работы был проведён анализ романа-эпопеи Л.Н. Толстого «Война и мир» с помощью модели LDA. После предобработки текста из него были выделены латентные темы. Оптимальное количество тем (18) позволило получить значение показателя когерентности тем, равное 0.4035.