


Лекция 5

Фильтрация на основе контента



Модель TF-IDF

$tf(\text{слово}, \text{документ})$ = сколько раз слово встречается в документе

$$tf(\text{слово}, \text{документ}) = \frac{\text{сколько раз слово встречается в документе}}{\text{общее количество слов в документе}}$$

$$tf(\text{слово}, \text{документ}) = \log(1 + \text{количество повторов слова})$$

$$idf(\text{слово}, \text{документ}) = \frac{\text{число всех документов}}{\text{количество документов с данным словом}}$$

$$idf(\text{слово}, \text{документ}) = \log \frac{\text{число всех документов}}{\text{количество документов с данным словом}}$$

Объединив эти два показателя получим TF-IDF.

$$tf-idf(x, y) = tf(x, y) \times idf(x, y).$$

В общем виде (!!! Используется логарифм по основанию 10 !!!).

$$w(x, y) = tf(x, y) \times \log \frac{N}{df(x)}$$

где

x – слово

y – документ

$w(x, y)$ – вес слова / значение характеристики $tf-idf$

$tf(x, y)$ – частота слова x в документе y

N – общее количество документов

$df(x)$ – количество документов, содержащих слово x .

Пример расчета TF-IDF

TF (частота термина) слова — это частота слова (т. е. количество раз, которое оно встречается) в документе. Зная TF, можно оценить часто ли используется данный термин.

Если описание из 100 слов содержит термин «кот» 12 раз, то TF для слова «кот» будет равен

$$TF(\text{кот}) = 12/100 = 0,12.$$

IDF (обратная частота документов) является показателем того, насколько значимо это слово во всем наборе описаний.

Допустим, размер набора составляет 10 000 описаний. Предположим, что существует 300 описаний, содержащих термин «кот». Тогда IDF определяется как логарифм отношения общего количества описаний (10 000) к количеству описаний, содержащих термин «кот» (300).

$$IDF(\text{кот}) = \log(10\,000/300) \approx 1,52$$


Расчет TF-IDF

$$W(\text{кот}) = TF(\text{кот}) * IDF(\text{кот}) = 0,12 * 1,52 = 0,1824$$


Показатель TF-IDF, равный 0,18, намного ближе к 0, чем к 1. Это говорит о том, что «кот» — это общий термин с меньшим весом.

Модель LDA

Общая идея алгоритма LDA. На вход подаются несколько документов и число K – количество тем, которое алгоритм должен создать. Выходом алгоритма является список K тем и список векторов, по одному на документ, в которых содержится вероятность появления каждой темы в данном документе.



K - количество тем, которые должна содержать модель LDA и множество документов, каждый из которых считается отдельным «мешком слов» Нужно соединить слова с темами и документы с темами.



Модель LDA более строго

В основе модели LDA лежит вероятностная модель существования пары документ-слово. Эту вероятность можно расписать по формуле умножений вероятностей:

$$p(d, w) = p(w|d) \cdot p(d).$$

p – вероятность, d – документ, w – термин (слово).

Введем обозначение Z – множество всех тем, z – отдельная тема. Тогда

$$p(d, w) = \sum_{z \in Z} p(w|z) \cdot p(z|d) \cdot p(d)$$

$$p(w|z) = \varphi, \quad p(z|d) = \theta$$

Определение переменных в модели LDA

Переменная	Тип	Значение
K	целое число	количество тем (например, 50)
V	целое число	количество слов в словаре (например, 50 000 или 1 000 000)
M	целое число	количество документов
$N_{d=1 \dots M}$	целое число	количество слов в документе d
N	целое число	общее количество слов во всех документах; сумма всех N_d , т.е. $N = \sum_{d=1}^M N_d$
$\alpha_{k=1 \dots K}$	Положительное рациональное (вещественное)	предшествующий вес темы k в документе; обычно одинаков для всех тем; обычно число меньше 1, например, 0,1, чтобы предпочесть разреженное распределение тем, т. е. несколько тем в документе.
α	K -мерный вектор положительных вещественных чисел	Все значения α_k рассматриваются как один вектор.

$\beta_{w=1 \dots V}$	Положительное рациональное (вещественное)	предшествующий вес слова w в теме; обычно один и тот же для всех слов; обычно число намного меньше 1, например, 0,001, чтобы настоятельно предпочесть разреженное распределение слов, т.е. несколько слов на тему.
β	V -мерный вектор положительных вещественных чисел	Все значения β_w рассматриваются как один вектор.
φ_{kw} $k = 1 \dots K,$ $w = 1 \dots V$	вероятность (действительное число от 0 до 1)	вероятность появления слова w в теме k
φ_k $k = 1 \dots K$	V -мерный вектор вероятностей, сумма элементов которого должна равняться 1	распределение слов в теме k
θ_{dk} $d = 1 \dots M,$ $k = 1 \dots K$	вероятность (действительное число от 0 до 1)	вероятность появления темы k в документе d
θ_d $d = 1 \dots M$	K -мерный вектор вероятностей, сумма элементов которого должна равняться 1	распределение тем в документе d
z_{dw} $d = 1 \dots M,$ $w = 1 \dots N_d$	целое число от 1 до K	идентичность (принадлежность) темы слова w в документе d
Z	N -мерный вектор целых чисел от 1 до K	идентичность темы всех слов во всех документах
w_{dw} $d = 1 \dots M,$ $w = 1 \dots N_d$	целое число от 1 до V	идентичность слова w в документе d
W	N -мерный вектор целых чисел от 1 до V	идентичность всех слов во всех документах

Тоже самое, но короче.

M обозначает количество документов

N — количество слов в данном документе (документ i имеет N_i слова)

α - параметр априорного распределения Дирихле по темам каждого документа.

β - параметр априора Дирихле для распределения слов по темам.

θ_i это распределение тем для документа i

φ_k это распределение слов по теме k

z_{ij} это тема для j -го слова в документе i

w_{ij} это конкретное слово.

Случайные величины математически описываются следующим образом:

$$\begin{aligned}\varphi_{k=1 \dots K} &\sim \text{Dirichlet}_V(\beta) \\ \theta_{d=1 \dots M} &\sim \text{Dirichlet}_K(\alpha) \\ z_{d=1 \dots M, w=1 \dots N_d} &\sim \text{Categorical}_K(\theta_d) \\ w_{d=1 \dots M, w=1 \dots N_d} &\sim \text{Categorical}_V(\varphi_{z_{dw}})\end{aligned}$$

Dirichlet – распределение Дирихле.

Categorical – категориальное распределение (или обобщенное распределение Бернулли).

В качестве примера использования распределения Дирихле можно предложить задачу, в которой требуется разрезать нитки (каждая начальной длины 1,0) на K частей с разными длинами так, чтобы все части имели заданную среднюю длину, но с возможностью некоторой вариации относительных длин частей. Значения α / α_0 определяют средние длины частей нитки, получившиеся из распределения. Дисперсия вокруг среднего значения обратно пропорциональна α_0 .

Толковая книга по теме - Кацов Илья. Машинное обучение для бизнеса и маркетинга. — СПб.: Питер, 2019.