

Персонализированные рекомендации.

Самые простые — всем рекомендуем одно и то же;
("С этим товаром часто берут");

Построение основано на асс. правил;

$I = \{i_1, \dots, i_n\}$ — объекты;

$T = \{t_1, \dots, t_n\}$ — транзакции (покупки)

асс. правило: $X \rightarrow Y$; $X, Y \in I$;

Транзакции представ. в виде таблицы: → объекты

ID	Молоко	Хлеб	Масло	Чай	Конфеты
1	1	1	0	0	0
2	0	0	1	0	0
3	0	0	0	1	1
4	1	1	1	0	0
5	1	1	0	0	0

1 — товар куплен, 0 — иначе;

1) Поддержка (support):

$$\text{supp}(x) = \frac{|\{t \in T, x \subseteq t\}|}{|T|} \quad \text{— по сути частота;}$$

2) Доверие (confidence): (Как часто при покупке А берут В?)

$$\text{conf}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X)};$$

По сути это условная вероятность;

$$\text{conf}(\{ \text{хлеб}, \text{молоко} \} \Rightarrow \text{молоко}) = 1/2;$$

3) Вер-ть покупки обоих товаров ...

$$\text{lift}(X \rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X) \cdot \text{supp}(Y)};$$

Оценка зав-ти товаров друг от друга (корреляция);

$$\text{lift}(\{ \text{молоко}, \text{хлеб} \} \rightarrow \{ \text{масло} \}) = \frac{0,2}{0,4 \cdot 0,4}$$

$\text{lift} > 1 \Rightarrow$ связь есть;

$= 1 \Rightarrow$ товары независимы;

$< \Rightarrow$ объекты заменяют друг друга;
(купят только что-то одно, но не всё);

4) Уверенность (conviction): частотность ошибок

$$\text{conv}(X \rightarrow Y) = \frac{1 - \text{supp}(Y)}{1 - \text{conf}(X \rightarrow Y)};$$

Как часто покупали X без Y?

Алгоритмы поиска ассоциативных правил
(а то полный перебор имеет эксп. сложность)


- Apriori;
- ECLAT;
- FP-Growth;

Apriori (1994, самый простой и популярный)

Основан на антимонотонности поддержки.

Поддержка набора $\leq$ мин. поддержка любого из элементов набора;

Эта идея позв. уменьшить пр-во поиска;
С ростом размера набора поддержки не воз-
растает;



Если при просмотре сверху вниз поддержка
падает ниже ^(нежно) ^(вспомогательная) порогов, то можно отбро-
сить узел и не идти дальше;

Пример:

$\{A, B, C\}$

$AB \rightarrow C$

F-набор (часто встречается)

$S \subseteq F$;

$S \rightarrow F - S$;

$\text{Conf}(S \rightarrow F - S) = \frac{\text{supp}(F)}{\text{supp}(S)}$;

Правила, построенные по этому дил., будут
коммутативными;

Параметры: (настройка)

- поддержка; (0,2 - 0,3);

- доверие; (0,7 - 0,9);

Поиск в ширину

Как сократить процесс?

ECLAT (Equivalence Class Transformation)

X - мк-во эл-тов;

$T(X)$ - мк-во транзакций, в кот. вступ-ся X ;

$t(XY) = t(X) \cap t(Y)$;

$\text{supp}(t(XY)) = \frac{|t(XY)|}{|T|}$;

$\hookrightarrow \text{const} \Rightarrow$ можно не делить;

Алг. основан на поиске в глубину;
 $\hookrightarrow$ оптимизируется

FP-Growth (2000)

Формирование компактного FP-дерева из ФД
ФД трансформируется 2 раза (а не n^2):

- подсчет частоты;
- построение дерева;

Проход от листьев к корню - нахождение наиболее частых наборов;

Растр. параметр: мин. уровень поддержки;

Узел дерева:

- ID;
- счётчик;

2) ^{сдать} готов. реализации всех алл. и подобрать
параметры;
в отчёте вместо особ-тей реализации
указать особ-ти примечения;

Срок - 24.09, просрочка - 35;
без отчёта на 15. меньше;