

- 1) Тестирование на бумаге ("ручная прокрутка")
- 2) Проверки в ходе реализации; (модульное тестирование)
+ регрессионное тестирование

Ошибки не найдены $\Rightarrow$ система работает

- 3) Подключаем юзеров
 - контрольная группа (юзеры, добровольно настроенные по отношению к системе)

Для анализа качества нужны количественные метрики;

Подходы к оценке:

- основанные на юзерах ($\sim$ заработок)

Что нравится юзеру:

- его вкусы понимают;
- рекомендации разнообразны;
- стирпы, но в меру;

? - рекомендации охватывают весь каталог?

$\hookrightarrow$ охват юзеров

$\hookrightarrow$ охват каталога

Каждый раз сист. должна рек-ть что-то новое

Метрики:

$$1) MAE = \frac{1}{n} \sum_{i=1}^n |r_i - p_i|$$

реальн. и предсказ.
оценка

$$2) MSE = \frac{1}{n} \sum_{i=1}^n (r_i - p_i)^2;$$

$$3) RMSE = \sqrt{MSE}; \text{ - стандарт}$$

- Чем больше размах оценок, тем больше ^{польза} вынесет на систему;
- знак в разнице оценок не учитывается;
(предсказ. и реальн.)

Объекты	Рекомендован	Не рекомендован
Просмотрен	TP	FN
Не просмотрен	FP	TN

⇒ можно считать Precision, Recall
 ↳ при оптимизации
 более предпочтительны

$$PK(u) = \frac{\text{кол-во релевантн. объектов}}{\sum_{k=1}^m PK(u)}^K$$

$$CT(u) = \left(\sum_{k=1}^m PK(u) \right)^K / m;$$

средн.
точн.

m - кол-во объектов в выдаче;

$P_1 = 1/1$
 $P_2 = 1/2$
 $P_3 = 2/3$
 $P_4 = 2/4$

$$CT = \frac{1 + 1/2 + 2/3 + 2/4}{4} = 2/3$$

- Гинссемма совокупная прибыль

$$ССП = \sum_{i=1}^K \frac{2^{rel(i)} - 1}{\log_2(i+2)};$$

+ можно нормировать по идеальной ССП;
(получена на идеальн. выборке)

Деление датасета

$\ddot{\cdot}$
K-fold cross-validation;